

SuiLLM Gateway

AI Agent Marketplace dengan Pembayaran Native SUI Token

Technical Brief & System Architecture

Sui Overflow 2026 — Agentic Web Track

Versi 1.0 | Mei 2026

Track	Agentic Web — Sui Overflow 2026
Kategori	AI Infrastructure + DeFAI + Developer Tooling
Stack Utama	Move (Sui) · Node.js · Next.js 14 · Walrus
Target User	Developer & dApp yang ingin bayar LLM dengan SUI
Prize Pool	\$500K+ total across core & sponsored tracks

1. Executive Summary

SuiLLM Gateway adalah platform infrastruktur yang memungkinkan developer, dApp, dan AI agent lain untuk mengakses berbagai Large Language Model (LLM) — termasuk Claude, GPT-4o, Gemini, dan model open source — dengan membayar menggunakan token SUI secara native on-chain.

Platform ini menjawab problem statement utama track Agentic Web: bagaimana membangun agentic commerce di atas Sui dengan payment rails yang cepat, programmable, dan atomic. Alih-alih memaksakan Web2 API key ke ekosistem Web3, SuiLLM membangun ulang model akses dan billing menggunakan primitif native Sui: Capability Objects, Programmable Transaction Blocks (PTB), dan Walrus untuk audit trail terdesentralisasi.

Aspek	Solusi SuiLLM
Masalah pembayaran LLM	Bayar dengan SUI/stablecoin, bukan kartu kredit
Akses untuk agent otomatis	NFT Capability Object — dapat dibeli, ditransfer, di-delegate
Multi-agent coordination	A2A Protocol + PTB atomic multi-purchase
Audit & transparansi	Usage log di Walrus, verifiable on-chain
Developer experience	OpenAI-compatible API — tinggal ganti base URL

2. Latar Belakang & Relevansi Track

Mysten Labs mendefinisikan Agentic Web sebagai web generasi berikutnya di mana AI agent dapat bertindak, bertransaksi, dan berkoordinasi secara otonom. Tiga pilar utama yang menjadi focus track ini adalah:

- **Agentic Commerce** — agent dapat membayar layanan secara otonom dengan spending cap yang terkontrol
- **Content Monetization** — situs dan API dapat memonetisasi akses dari agent
- **Identity & Authentication** — identitas kriptografis untuk human, agent, dan agent-acting-on-behalf-of-human

SuiLLM menjawab ketiga pilar ini sekaligus: platform adalah marketplace di mana LLM provider memonetisasi inference mereka kepada agent/developer, dengan identitas berbasis Sui object, dan pembayaran atomic menggunakan PTB — persis seperti demo A2A yang dipamerkan Mysten Labs dalam kolaborasinya dengan Google Cloud.

Kompetisi langsung di ekosistem Sui: Atoma (decentralized inference), Suithetic (synthetic data), dan RaidenX (DeFAI trading) sudah ada, tapi belum ada yang fokus ke 'LLM-as-a-payable-service dengan SUI' untuk developer umum dengan API yang compatible dengan standar OpenAI.

3. Arsitektur Sistem

Sistem terdiri dari 5 layer utama yang berinteraksi satu sama lain. Setiap layer memiliki tanggung jawab yang terisolasi untuk kemudahan testing, scaling, dan maintenance.

Layer	Nama	Teknologi	Fungsi Utama
L1	User Interface	Next.js 14, @mysten/dapp-kit	Dashboard, wallet connect, API key management
L2	Smart Contract	Move on Sui	Payment, access control, quota, registry
L3	Gateway Backend	Node.js / Bun, Redis	Auth verify, LLM routing, usage metering, settler
L4	LLM Providers	Anthropic, OpenAI, Google, Atoma	Inference engine — dikonsumsi oleh gateway
L5	Data Layer	Walrus, PostgreSQL, Redis	Audit log, metadata, cache quota

3.1 Smart Contract Architecture (Move on Sui)

Smart contract adalah inti dari keseluruhan sistem. Dirancang sebagai 4 module yang terpisah namun saling berinteraksi dalam satu package:

Module 1: payment_module

Mengelola seluruh aliran keuangan platform.

- Escrow SUI token dari user ke platform treasury
- Support stablecoin (USDC on Sui) untuk harga yang stabil
- Per-token billing: 1 SUI = N inference tokens (konfigurasi via governance)
- PTB atomic multi-payment: satu tx bisa bayar beberapa agent sekaligus
- Revenue split otomatis ke LLM provider, platform fee, dan staking reward

Module 2: access_module

API key direpresentasikan sebagai Sui Capability Object (NFT), bukan string di database. Ini adalah perbedaan fundamental dari sistem Web2 biasa:

- **ApiCapObject**: Sui object yang dimiliki user, berisi allowlist model dan tier akses
- Bisa ditransfer ke wallet lain (jual, delegate ke agent)
- Bisa di-burn untuk refund sisa quota
- Verifikasi: gateway query Sui RPC — tidak perlu trust database off-chain

Module 3: quota_module

- **QuotaObject**: menyimpan saldo token inference yang tersisa
- **SpendCapObject**: batas maksimal pengeluaran per periode (keamanan agent otonom)
- Top-up kapan saja tanpa membuat object baru
- Auto-refund jika request gagal di sisi LLM provider

Module 4: registry_module

- Daftar model yang tersedia beserta harga per 1K token (input & output)
- Agent capability: model dapat didaftarkan sebagai 'agent' dengan kemampuan tertentu
- Revenue split config per provider (persentase ke provider, platform, staking)
- Governance: parameter dapat diubah via multisig atau DAO vote

Contoh struktur Move module (quota_module):

```
module suilllm::quota_module {
  use sui::object::{Self, UID};
  use sui::coin::{Self, Coin};
  use sui::sui::SUI;

  public struct QuotaObject has key, store {
    id: UID,
    owner: address,
    token_balance: u64,      // remaining inference tokens
    spend_cap_per_day: u64, // max tokens per 24h (for agents)
    used_today: u64,
    last_reset_epoch: u64,
  }

  public fun topup(quota: &mut; QuotaObject, payment: Coin, rate: u64) {
    let tokens = coin::value(&payment;) * rate;
    quota.token_balance = quota.token_balance + tokens;
    // transfer payment to treasury...
  }

  public(friend) fun deduct(quota: &mut; QuotaObject, amount: u64) {
    assert!(quota.token_balance >= amount, EInsufficientBalance);
    quota.token_balance = quota.token_balance - amount;
  }
}
```

3.2 Gateway Backend

Backend ditulis dengan Node.js (atau Bun untuk performa lebih tinggi) dan berfungsi sebagai jembatan antara dunia on-chain dan LLM provider. Dirancang stateless untuk horizontal scaling.

Komponen	Teknologi	Fungsi
Auth Verifier	Sui SDK + Ed25519	Query RPC untuk verifikasi kepemilikan ApiCapObject
Request Router	Express.js / Hono	Pilih LLM provider berdasarkan model yang diminta
Streaming Proxy	SSE / WebSocket	Forward streaming response dari LLM ke user real-time
Usage Metering	Tiktoken + Redis	Hitung token input/output, simpan di antrian settlement
Settlement Service	Sui SDK + PTB	Batch deduct quota on-chain setiap 60 detik
Rate Limiter	Redis + Sliding Window	Enforce SpendCapObject limits sebelum forward ke LLM
Log Writer	Walrus SDK	Tulis audit log per-request ke Walrus (immutable)

Gateway mengimplementasikan OpenAI-compatible API (**POST /v1/chat/completions**, **POST /v1/embeddings**, **GET /v1/models**) sehingga developer tidak perlu mengubah kode yang sudah menggunakan OpenAI SDK — cukup ganti base URL dan tambahkan header autentikasi Sui.

Header autentikasi kustom:

```
// Request header dari client
X-Sui-Object-Id: 0xabc123... // ID dari ApiCapObject user
X-Sui-Signature: // Signature dari wallet user
X-Sui-Timestamp: 1716400000 // Unix timestamp (prevent replay attack)

// Gateway verifikasi:
// 1. Query Sui RPC: apakah object_id exist & owner match address dari signature?
// 2. Verify Ed25519 signature atas pesan: object_id + timestamp
// 3. Check quota di Redis cache (fallback ke on-chain RPC jika cache miss)
```

3.3 Frontend Dashboard (Next.js 14)

Dashboard dibangun dengan Next.js 14 App Router, menggunakan @mysten/dapp-kit untuk integrasi wallet Sui. Desain mengikuti Sui Wallet Standard sehingga kompatibel dengan semua wallet di ekosistem Sui (Sui Wallet, Martian, Suiet, dsb.).

Halaman / Komponen	Fungsi
/ (Landing)	Penjelasan platform, CTA connect wallet, pricing tiers
/dashboard	Overview: saldo SUI, quota tersisa, total request, chart penggunaan 30 hari
/dashboard/topup	Top-up quota: pilih jumlah SUI, konfirmasi tx, real-time balance update
/dashboard/api-keys	Daftar ApiCapObject, generate baru, revoke, transfer, set SpendCap
/dashboard/models	Marketplace model: browse model, harga per 1K token, latency benchmark
/dashboard/usage	Log penggunaan per request: model, token, biaya SUI, timestamp, Walrus hash
/dashboard/settings	Notifikasi low-balance, webhook URL, spending alert
/playground	Test prompt langsung dari browser, pilih model, lihat usage real-time
/docs	API reference, code examples (Python, Node.js, curl), SDK quickstart

Tech stack frontend lengkap: **Next.js 14** (App Router), **TypeScript**, **Tailwind CSS**, **shadcn/ui**, **@mysten/dapp-kit** (wallet), **@mysten/sui.js** (SDK), **Recharts** (charts), **React Query** (data fetching), **Zustand** (state), **Vercel** (deployment).

4. Workflow User — Step by Step

4.1 Onboarding: Daftar & Top-Up Pertama

Step	Aksi User	Yang Terjadi di Sistem
1	Kunjungi suilllm.xyz, klik 'Connect Wallet'	App-kit membuka Sui wallet popup
2	Approve koneksi di wallet	Alamat wallet disimpan di session, dashboard terbuka
3	Klik 'Top-Up Quota', masukkan jumlah SUI (mis. 10 SUI)	Contract mint SUI transaction: transfer 10 SUI ke contract + mint QuotaObject
4	Approve tx di wallet	Contract: terima SUI, buat QuotaObject dengan balance = 10 SUI × rate
5	Dashboard refresh	Balance quota muncul: mis. '500,000 inference tokens'
6	Klik 'Generate API Key'	Contract mint ApiCapObject (NFT), dikirim ke wallet user. Object ID = AP
7	Copy API key identifier (object ID)	Siap digunakan untuk call gateway API

4.2 Developer: Integrasi ke Aplikasi

Setelah onboarding selesai, developer mengintegrasikan ke aplikasi mereka. Karena gateway kompatibel dengan OpenAI SDK, integrasi hanya butuh 3 baris perubahan:

Contoh integrasi Python:

```
from openai import OpenAI

client = OpenAI(
    base_url='https://api.suilllm.xyz/v1',
    api_key='dummy', # tidak dipakai, autentikasi lewat header
    default_headers={
        'X-Sui-Object-Id': '0xabc123...', # ApiCapObject ID
        'X-Sui-Signature': wallet.sign(...),
        'X-Sui-Timestamp': str(int(time.time())),
    }
)

response = client.chat.completions.create(
    model='claude-sonnet-4', # atau 'gpt-4o', 'gemini-2.0-flash'
    messages=[{'role': 'user', 'content': 'Halo!'}]
)
print(response.choices[0].message.content)
```

Contoh integrasi JavaScript / Node.js:

```
import OpenAI from 'openai';

const client = new OpenAI({
  baseUrl: 'https://api.suilllm.xyz/v1',
  apiKey: 'dummy',
  defaultHeaders: {
    'X-Sui-Object-Id': process.env.SUI_CAP_OBJECT_ID,
```

```
    'X-Sui-Signature': await wallet.signMessage(payload),
    'X-Sui-Timestamp': Date.now().toString(),
  },
});

const stream = await client.chat.completions.create({
  model: 'claude-sonnet-4',
  messages: [{ role: 'user', content: 'Tell me about Sui blockchain' }],
  stream: true,
});
for await (const chunk of stream) process.stdout.write(chunk.choices[0]?.delta?.content
|| '');
```

4.3 AI Agent Otonom: A2A Protocol

Salah satu fitur paling kuat SuiLLM adalah dukungan untuk agent otonom yang dapat membeli quota dan menggunakan LLM tanpa intervensi manusia, menggunakan A2A Protocol yang dikembangkan Mysten Labs + Google:

Step	Actor	Aksi	Mekanisme Sui
1	Orchestrator Agent	Deteksi kebutuhan LLM call	—
2	Orchestrator Agent	Query registry model & harga	Read dari registry_module on-chain
3	Orchestrator Agent	Build PTB: top-up + mint ApiCap + mint Programmable Transaction Block	—
4	Sui Network	Eksekusi PTB secara atomic	Jika gagal di salah satu step, seluruh tx rollback
5	Gateway	Terima request dengan ApiCap baru	Verifikasi on-chain, lanjut ke LLM
6	LLM Provider	Proses request, return response	—
7	Gateway	Catat usage, trigger settlement	Batch deduct via PTB berikutnya
8	Walrus	Simpan audit log	Hash log ditempel ke QuotaObject events

SpendCapObject memastikan agent otonom tidak bisa menghabiskan lebih dari batas yang ditetapkan user. Contoh: user set SpendCap 50 SUI per hari — agent tidak bisa melebihi batas ini bahkan jika memiliki akses penuh ke wallet. Ini adalah keamanan native on-chain, bukan rate limit di level API.

5. Workflow Sistem — Alur Internal

5.1 Request Lifecycle (Per Request)

#	Komponen	Operasi	Estimasi Latency
1	Client	Kirim POST /v1/chat/completions + auth headers	—
2	Gateway: Rate Limiter	Check IP rate limit (Redis)	< 1ms
3	Gateway: Auth Verifier	Verifikasi Ed25519 signature (cryptographic)	< 2ms
4	Gateway: Auth Verifier	Query Redis: apakah quota object valid & balance cukup?	< 1ms
4b	Gateway (cache miss)	Fallback: query Sui RPC untuk verifikasi on-chain	50–150ms
5	Gateway: Rate Limiter	Check SpendCap harian dari Redis	< 1ms
6	Gateway: Router	Pilih LLM provider berdasarkan header 'model'	< 1ms
7	LLM Provider	Proses inference, stream response	500ms – 30s
8	Gateway	Proxy streaming ke client via SSE	Real-time
9	Gateway: Metering	Hitung token (tiktoken), push ke Redis queue	< 1ms async
10	Settlement Service	Setiap 60s: batch PTB deduct quota untuk semua request	400ms (Sui)
11	Log Writer	Tulis audit entry ke Walrus (async)	Background

Total latency overhead SuiLLM vs direct LLM call: **+3–5ms** (cache hit) atau **+50–160ms** (cache miss, RPC query). Untuk use case LLM yang biasa memakan ratusan ms hingga beberapa detik, overhead ini tidak signifikan.

5.2 Settlement Workflow (Batch per 60 Detik)

Settlement tidak dilakukan per-request (terlalu mahal gas) melainkan di-batch menggunakan Programmable Transaction Block (PTB) Sui yang memungkinkan ratusan deduction dalam satu transaksi atomic:

Step	Operasi
1. Collect	Settlement service baca semua pending usage dari Redis queue
2. Aggregate	Group by user object ID, sum token usage per user
3. Build PTB	Buat satu PTB yang berisi: deduct(user1, amount1), deduct(user2, amount2), ...
4. Submit	Kirim PTB ke Sui network. Jika user tidak punya cukup quota, tx-nya di-skip
5. Finalize	Setelah tx confirmed, hapus dari Redis queue, update cache
6. Events	Smart contract emit events, frontend update balance real-time via websocket
7. Log	Hash dari settled tx ditambahkan ke Walrus audit entry

PTB memungkinkan ratusan operasi dalam satu transaksi Sui dengan biaya gas yang jauh lebih efisien dibanding ratusan tx terpisah. Ini adalah differentiator teknis kunci SuiLLM dibanding sistem serupa di blockchain lain yang harus bayar gas per-deduction.

5.3 Quota Management & Error Handling

Skenario	Handling
Quota habis di tengah request	Gateway cek balance sebelum forward; tolak dengan error 402
LLM provider error (5xx)	Gateway retry 1x dengan backoff, jika gagal: tidak deduct quota
Sui network congestion	Settlement retry dengan exponential backoff, max 5 menit
ApiCapObject ditransfer	Cache invalidation otomatis, verifikasi jatuh ke RPC
SpendCap terlampaui	Tolak request dengan error 429 + pesan 'daily spend cap reached'
User top-up saat ada pending settle	PTB idempoten — tidak ada race condition

6. Model Marketplace & Pricing

Harga ditetapkan dalam SUI per 1 juta token (1M tokens). Gateway menambahkan margin platform di atas biaya provider. Harga SUI mengikuti oracle price feed on-chain (mis. Pyth Network) dan diupdate setiap 15 menit.

Model	Provider	Input (SUI/1M tokens)	Output (SUI/1M tokens)	Latency	Use Case
claude-sonnet-4	Anthropic	~0.8 SUI	~4 SUI	Sedang	General, coding
claude-opus-4	Anthropic	~2.5 SUI	~15 SUI	Lambat	Complex reasoning
gpt-4o	OpenAI	~0.6 SUI	~2.5 SUI	Cepat	Multimodal
gpt-4o-mini	OpenAI	~0.03 SUI	~0.15 SUI	Sangat cepat	High volume, cheap
gemini-2.0-flash	Google	~0.05 SUI	~0.2 SUI	Sangat cepat	Agentic tasks
llama-3-70b	Atoma/Self-host	~0.1 SUI	~0.1 SUI	Sedang	Open source, privacy
mistral-large	Atoma/Self-host	~0.15 SUI	~0.6 SUI	Cepat	European compliance

** Harga estimasi berdasarkan konversi dari USD menggunakan SUI price ~\$5. Harga aktual bervariasi mengikuti oracle feed. Platform fee: 15% dari setiap inference.*

7. Keamanan Sistem

Vektor Ancaman	Mitigasi
Replay attack (reuse signature)	Timestamp dalam signature + nonce di Redis; signature expired setelah 30 detik
Stolen API key (object ID bocor)	Butuh signature dari private key wallet — object ID alone tidak cukup
Man-in-the-middle	Semua komunikasi TLS. Gateway hanya expose HTTPS endpoint
Over-spending oleh agent	SpendCapObject on-chain — batas tidak bisa di-bypass meski gateway dikompromi
Gateway downtime	Quota tetap aman di chain. User bisa ganti ke gateway lain yang baca contract y
LLM provider data leak	Gateway tidak log prompt/response. Hanya token count yang dicatat di Walrus
Smart contract exploit	Formal verification dengan Move Prover. Audit eksternal sebelum mainnet
Sybil attack (banyak wallet palsu)	Tidak masalah — setiap wallet harus top-up SUI nyata. Tidak ada free tier

8. Schema Database (PostgreSQL — Off-chain Metadata)

PostgreSQL hanya menyimpan metadata yang tidak perlu on-chain (untuk performa dashboard). Ground truth tetap di Sui blockchain dan Walrus.

Tabel	Kolom Utama	Keterangan
users	wallet_address (PK), created_at, notified_at	Profil user, tidak perlu data sensitif

Tabel	Kolom Utama	Keterangan
api_cap_objects	object_id (PK), wallet_address (FK)	Table metadata API Cap Object dari chain
usage_logs	id, object_id (FK), model, input_tokens, output_tokens, tokens_deducted, request_time, wall_time (seconds)	Log penggunaan token, token debit, request time, wall time
settlements	tx_digest, object_id, tokens_deducted, settled_block_height	Record settlement block height sudah confirmed on-chain
models	model_id (PK), provider, input_price, output_price, registry_module	Cache harga model dari registry module

9. Tech Stack Lengkap

Kategori	Teknologi	Versi / Notes
Blockchain	Sui Mainnet	Object-centric model, PTB, Move
Smart Contract	Move	4 modules: payment, access, quota, registry
Contract Dev	Sui CLI + Move Prover	Formal verification, unit tests
Gateway Runtime	Bun (preferred) / Node.js 22	Hono framework, TypeScript
Gateway Auth	@mysten/sui.js + Ed25519	On-chain verification, no JWT
Gateway Cache	Redis 7 (Upstash / self-host)	Quota cache, rate limit, settlement queue
LLM Routing	Anthropic SDK, OpenAI SDK, Vertex AI SDK	Pluginable adapters per provider
Token Counting	tiktoken (OpenAI) + claude-token-counter	Exact count sebelum forward
Decentralized Storage	Walrus SDK	Audit log immutable, 80% lebih efisien dari Filecoin
Frontend	Next.js 14 (App Router)	TypeScript, Tailwind CSS, shadcn/ui
Wallet Integration	@mysten/dapp-kit	Sui Wallet Standard — semua wallet kompatibel
Charts / Analytics	Recharts + Tremor	Usage charts di dashboard
Database	PostgreSQL (Supabase / Neon)	Off-chain metadata & dashboard cache
ORM	Drizzle ORM	Type-safe, edge-compatible
API Layer	tRPC	End-to-end typesafe frontend-backend
Deployment: Frontend	Vercel	Edge functions, global CDN
Deployment: Gateway	Railway / Fly.io + Docker	Multi-region untuk latency rendah
Deployment: Contract	Sui Mainnet / Testnet	Package publish via Sui CLI
Monitoring	Grafana + Prometheus	Gateway metrics, settlement health
CI/CD	GitHub Actions	Auto test + deploy on merge to main

10. Timeline Pengembangan (Hackathon MVP)

Minggu	Focus	Deliverable
Minggu 1	Smart Contract Core	payment_module + quota_module selesai, unit tests passing, deploy ke Testnet
Minggu 2	Gateway Backend	Auth verifier + request router + 1 LLM provider (Claude). Endpoint /v1/chat/completions
Minggu 3	Settlement + Walrus	Batch settlement via PTB, Walrus log writer, Redis queue, settlement service
Minggu 4	Frontend Dashboard	Wallet connect, top-up flow, API key generation, usage dashboard
Minggu 5	Multi-provider + Registry	Tambah GPT-4o + Gemini, registry_module, model marketplace halaman

Minggu	Focus	Deliverable
Minggu 6	Polish + Demo	Error handling lengkap, playground page, dokumentasi API, video demo, dep

Tim yang direkomendasikan: 3 orang. (1) Blockchain engineer: Move smart contract + Sui SDK. (2) Backend engineer: Gateway, Redis, Walrus integration. (3) Frontend engineer: Next.js dashboard, wallet integration, UX.

11. Differentiators & Kriteria Penjurian

Kriteria Juri	Implementasi SuiLLM	Skor Potensi
Inovasi teknis	API key sebagai Sui Object, PTB batch settlement, Spend batching on-chain	Sangat tinggi
Relevansi track Agentic Web	Langsung menjawab 3 pilar: commerce, monetization, identity	Sangat tinggi
Penggunaan fitur unik Sui	PTB, Object model, Move safety, Walrus, zkLogin support	Sangat tinggi
Developer experience	OpenAI-compatible — zero learning curve untuk developer	Tinggi
Skalabilitas	Horizontal gateway + PTB batch = bisa handle ribuan request	Tinggi
Kelayakan bisnis	Model monetisasi jelas: 15% platform fee dari setiap inference	Tinggi
Kualitas demo	Live demo: agent otonom beli quota + call LLM + lihat on Sui Explorer	Sangat tinggi

12. Roadmap Post-Hackathon

Phase	Periode	Target
Phase 1: MVP	Hackathon	Single gateway, Claude + GPT-4o, basic dashboard
Phase 2: Multi-region	Bulan 1-2	3 gateway region (Asia, EU, US), latency < 100ms global
Phase 3: Marketplace	Bulan 2-4	Provider bisa daftarkan model sendiri, DAO governance pricing
Phase 4: Fine-tuning	Bulan 4-6	Upload fine-tuned model ke Walrus, monetize via registry
Phase 5: zkTLS Privacy	Bulan 6-9	Prompt tidak terlihat oleh gateway dengan zkTLS / TEE
Phase 6: Ecosystem	Bulan 9-12	SDK untuk 5 bahasa, plugin untuk LangChain, CrewAI, AutoGen

SuiLLM Gateway memposisikan diri sebagai infrastruktur kritis untuk ekosistem AI agentic di atas Sui — bukan sekadar demo hackathon, tapi fondasi untuk marketplace inference terdesentralisasi yang bisa berkembang menjadi protokol terbuka seperti yang Mysten Labs bayangkan untuk Agentic Web.

Kontak tim: [email@team.xyz] | GitHub: github.com/team/suillm | Testnet: testnet.suillm.xyz